

Kunstig intelligens får skylda for et enormt strømforbruk den ikke har (Addendum)

Karl Audun Borgersen
karl.audun.borgersen@uia.no

Morten Goodwin
morten.goodwin@uia.no

Rebekka Olsson Omslandseter
rebekka.o.omslandseter@uia.no

October 27, 2025




Figure 1: Bilde generert av Qwen Image på en desktop PC. Genereringen tok $\sim 0.981Wh$

Abstract

I alle tilfeller, når en skriver en folkelig kronikk på under 6000 tegn er det detaljer som går tapt i spinningen. Denne artikkelen er tenkt som et addendum til kronikken "Kunstig intelligens får skylda for et enormt strømforbruk den ikke har" for å gi en konkret og mer teknisk forklaring rettet mot dere som vet hva en GPU er, men som ikke nødvendigvis er helt med på det nyeste innen KI.

Artikkelen er strukturert med en innledende del som gir en introduksjon, etterfulgt av en rekke avsnitt som gir kommentarer om ulike valg tatt i den opprinnelige kronikken. Dette inkluderer beslutninger knyttet til valg av språkmodeller, anvendt maskinvare og andre relevante aspekter.

Table 1: Effekt- og energiforbruk for diverse enheter

Aktivitet / Enhet	Omtrentlig effekt (W)	Ca. forbruk per bruk (Wh)
Vannkoker (1 liter vann)	2000	66
Hårføner (5–10 min bruk)	1500–2000	50–66
Vaskemaskin (én vask, 40 °C)	500–1000	750–1500
Tørketrommel (én tørkerunde)	3000–5000	4500–7500
Mobiltelefon (full opplading)	20	40
ChatGPT OSS (et minutt)	220	3.7
Deep Seek (et minutt)	480	8

Table 2: Effekt- og energiforbruk for diverse enheter

Aktivitet / Enhet	Omtrentlig effekt (W)	Ca. forbruk per bruk (Wh)
Vannkoker (1 liter vann)	2000	66
Hårføner	1500–2000	50–66
Vaskemaskin (40 °C)	500–1000	750–1500
Tørketrommel	3000–5000	4500–7500
Mobiltelefon	20	40
Classic lyspære	11	1.1
Lade Tesla Model Y	3600	61 200
ChatGPT OSS supermaskin	220	3.6
Deep Seek supermaskin	480	8
ChatGPT OSS Hjemmepc	60	1
Forbruk OpenAI selv hevder	–	0.34

1 Størrelse på språkmodeller

Grovt forenklet kan vi se på alle språkmodeller¹ som en eneste stor matteligning der vi har et fast antall parametere. Når en har trent opp systemer som etterligner menneskelig tale på det viset som moderne språkmodeller gjør er disse ligningene naturligvis ikke noe en kan løse på en tavle. De språkmodellene du kanskje tar i bruk på nettet slik som ChatGPT eller Mistral er i essensen regnestykker som (sannsynligvis) består av hundrevis av milliarder av parametere, kanskje til og med opp til litt over en billion på det meste. Disse ligningene knekkes flere ganger når språkmodellen skriver et enkelt svar. Slikt sett er det nesten et under at vi klarer å gjøre dette på sekunder i det hele tatt!

Gitt at OpenAI vanligvis ikke offentliggjør størrelsen på språkmodellene sine, har en observant leser kanskje merket seg at vi i forrige avsnitt nevnte “hundrevis av milliarder til en billion” parameter i forrige avsnitt. Dette er da en ganske betydelig forskjell i størrelse? Det er helt riktig, og det er også kilden til at det er ganske vanskelig å komme med konkrete utspill når det gjelder en språkmodell sitt strømforbruk. “Store” språkmodeller kan nemlig på det aller minste være på størrelse med et par hundre *millioner*, disse kan komfortabelt kjøres lokalt på ens egen smarttelefon uten at batteriprosenten flytter på seg. Nedsiden med disse små store språkmodellene er en dramatisk nedgang i hvor nyttige de er. En språkmodell som kan kjøre på din telefon klarer kanskje å lystre noen enkle instruksjoner², men kommer ikke til å være stort til hjelp utenom det. Den kunnskapen en språkmodell har innebygget blir på et vis lagret i parameterne dens. Jo flere parametere, jo mer kunnskap har en språkmodell potensialet til å tilegne seg. Dette inkludere forresten også norskkunnskaper, jo mindre språkmodellen er, jo vanskeligere kommer den for å ha for å kommunisere på norsk.

¹I dette blogginnlegget kommer vi til å bruke uttrykket “språkmodeller” som en fornorskning av “LLM” eller “Large Language Model” ettersom dette er en mer presis måte å referere til hva media ofte ganske enkelt kaller “KI”.

²I retning: “Tell fra en til ti”

2 Valg av modeller

Det finnes drøsevis av forskjellige modeller som har blitt sluppet som “open source”, det vil si at vi har muligheten til å velge å kjøre dem på våre egne servere. Den mest kjente av disse med god margin er nok sannsynligvis Deepseek, en kinesisk språkmodell. Å sende meldinger til Deepseek[1] føles temmelig likt som å sende meldinger til ChatGPT. Den presterer også ca. på samme nivå på de utallige forskjellige oppgavene vi i maskinlæringsverdenen har utarbeidet for å teste hvor gode språkmodeller faktisk er. Dette er derfor den mest oppriktige sammenligningen til ChatGPT vi som ikke jobber for OpenAI har tilgang til per nå. Deepseek er på 685 milliarder parametere totalt. Vi vet ikke hvor stor ChatGPT 5 er, men vi kan være så godt som sikre på at den er i samme størrelsesorden som Deepseek.

For et par måneder siden lanserte OpenAI, for første gang på seks år, sin egen duo med åpne språkmodeller kalt GPT-OSS. Den største av disse er på 120 milliarder parametere og er den vi valgte å bruke for våre forsøk. Det skal nevnes at denne er relativt lettvektig i drift pga. noen fiffige forbedringer i språkmodellarkitekturer som har blitt populære de siste par månedene. Den presterer også bedre enn mange av de eldre modellene fra OpenAI på flere relevante statistikker som er ment for å evaluere hvor god en språkmodell er[2]. Denne ble valgt fordi merket GPT er mest gjenkjennbart for de fleste lesere, men den er også høyst sannsynlig betydelig mer lettvektig enn de tyngste modellen som leveres på OpenAI sine nettsider.

3 OpenAI sine påstander

For fire måneder siden la OpenAI sin CEO, Sam Altman, ut et blogginnlegg som blant annet kom med noen påstander rundt strømforbruket på en gjennomsnittlig query (0,34 W/h)[3]. Dessverre har vi som eksterne forskere ingen mulighet til å etterprøve disse tallene. Det finnes flere eksterne faktorer som kan bidra til å trekke ned gjennomsnittlig strømforbruk. Vi vet blandt annet at OpenAI har en intern router som baserer størrelsen på språkmodellen som svarer basert på kompleksiteten til forespørselen. Lengden på en gjennomsnittlig query er heller ikke forklart. I vår tabell har vi gått ut fra at språkmodellene skriver en query på ca. et minutt. Det er godt mulig at en gjennomsnittlig query og tilsvarende svar er betydelig mindre enn dette. Tallene Sam Altman viser til, er sannsynligvis mer representative for deres mindre interne modeller. Basert på våre beregninger er nok OpenAI sine større modeller mer sammenlignbare med våre tall på DeepSeek modellen.

4 Hardware

Vi på Universitetet i Agder (UiA) er såpass heldige at vi har tilgang til flere SotA ³ superkomputere som kan kjøre språkmodeller på størrelse med det vi kan anta at brukes i ChatGPT. Superdatamaskinen vi har brukt til disse forsøkene er utstyrt med 8 NVIDIA H100 GPUer med 80 GB VRAM hver. Altså 400 GB VRAM totalt.

4.1 Konsumerhardware

GPT-OSS 120b er noe en litt over gjennomsnittlig interessert person med en gaming-PC fint kan kjøre på sin egen maskin. 120B er et antall parameter som høyst sannsynlig ikke vil få plass på en enkelt konsumer GPU. Mesteparten av parameterne blir derfor avlastet til RAM. Konter intuitivt nok minker dette det totale forbruket til modellen, i bytte mot at teksten genereres betydelig tregere. Der UiA sin server brukte 220W for å kjøre GPT-OSS, bruker denne konsumerPCen kun rundt 60W. Mye av forskjellen skyldes overheaden som kreves for å drifte den langt heftigere servere, samt at mesteparten av modellen på konsumerpcen er lastet over til RAM.

5 Vannforbruk

Vannforbruk er et hett tema når det gjelder hvordan språkmodeller påvirker klimaet. Dette er dessverre ikke noe vi kan empirisk teste selv ettersom våre servere er kjølt med luft og et lukket

³“State of the Art”

vannkjølingssystem. Dermed forbruker ikke serveren vann direkte hvis vi ser bort fra indirekte kostnader slik som konstruksjonen av bygget og produksjonen av maskinene. I følge Mistral står dette kun for rundt 10% av det totale vannforbruket av å trene en språkmodell [4].

6 Andre betraktninger

Når det kommer til språkmodeller, er det ofte ikke selve kjøringen som krever mest datakraft, men snarere treningsprosessen i utgangspunktet. Avhengig av modellens popularitet, kan kostnadene ved trening være betydelig høyere enn kostnadene for selve kjøringen.

Våre beregninger av strømforbruk er også gjort i et vakuum med kun én forespørsel som kjøres om gangen. Høyst sannsynlig tjener de store KI-leverandørene på skaleringen av antall forespørsler som de kjører samtidig på deres datasentre slik at hver individuell query blir billigere strømmessig.

References

- [1] DeepSeek-AI, “DeepSeek-V3 Technical Report,” Feb. 2025, **Merk:** Dette er på lang vei den mest grundige rapporten DeepSeek har utgitt, men den handler ikke om den nyeste utgaven av DeepSeek, som ble lansert separat et par måneder senere. [Online]. Available: <http://arxiv.org/abs/2412.19437>
- [2] OpenAI, “gpt-oss-120b & gpt-oss-20b Model Card,” Aug. 2025, arXiv:2508.10925 [cs]. [Online]. Available: <http://arxiv.org/abs/2508.10925>
- [3] S. Altman, “The gentle singularity,” 2025. [Online]. Available: <https://blog.samaltman.com/the-gentle-singularity>
- [4] Mistral AI, “Our contribution to a global environmental standard for ai,” <https://mistral.ai/news/our-contribution-to-a-global-environmental-standard-for-ai>, jul 2025, accessed: 2025-09-10.